ANKARA ÜNİVERSİTESİ

MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

BLM4522 – Ağ Tabanlı Paralel Dağıtım Sistemleri

Veri Temizleme ve ETL Süreçleri Tasarımı

Github -> https://github.com/GunIsmail/BLM4522-AgTabanliParalelDagitimSistemleri

İSMAİL GÜN – 22290280

15.04.2026

1. Projenin Amacı

Bu projede Microsoft SQL Server kullanılarak büyük veri kümeleri üzerinde ETL (Extract, Transform, Load) süreçleri uygulanmıştır. Amaç; farklı kaynaklardan gelen kirli ve tutarsız verilerin analiz edilmesi, veri temizleme işlemleri ile hatalı ve eksik kayıtların düzeltilmesi ve verilerin standart bir formata dönüştürülerek hedef tabloya aktarılmasını sağlamaktır.

Ayrıca bu proje kapsamında veri kalitesinin artırılması, veri uyumsuzluklarının giderilmesi ve temiz veri üzerinden analiz yapılabilir hale getirilmesi hedeflenmiştir. Gerçek dünya senaryolarına uygun olarak veri temizleme, veri dönüştürme ve veri yükleme adımları uygulanmış ve süreç sonunda veri kalitesi raporları oluşturulmuştur.

2. Veritabanı Oluşturma

İlk olarak VizeProject2DB isimli veritabanı oluşturulmuştur.

Bu adımda sistemde yeni bir veritabanı tanımlanarak proje için çalışma ortamı hazırlanmıştır.

```
--- -- - - - Database olusturma islemi yaptim .  - - --- - -- - - -
--USE VizeProject2DB;
--GO
```

Şekil 1 : Veri Tabanı oluşturma

3. Tabloların Oluşturulması

Bu projede ETL sürecinin uygulanabilmesi amacıyla veritabanı içerisinde üç farklı tablo oluşturulmuştur:

- **RawCustomers_Source1:**
  Birinci veri kaynağından gelen ham (kirli) müşteri verilerini tutmaktadır. Bu tabloda veri temizleme işlemi yapılmamış olup eksik, hatalı ve tutarsız kayıtlar bulunmaktadır.

- **RawCustomers_Source2:**
  İkinci veri kaynağından gelen müşteri verilerini içermektedir. Bu tablo, farklı

isimlendirme ve veri formatlarına sahip alanlar içerdiğinden veri dönüştürme işlemleri için kullanılmıştır.

- **CleanCustomers:**
  ETL süreci sonucunda temizlenmiş ve standartlaştırılmış verilerin aktarıldığı hedef tablodur. Bu tablo yalnızca geçerli ve düzenlenmiş verileri içermektedir.

Bu yapı sayesinde farklı veri kaynaklarından gelen veriler ayrı ayrı analiz edilmiş, ardından temizlenerek ortak bir yapıda birleştirilmiştir. Böylece veri entegrasyonu sağlanmış ve veri kalitesi artırılmıştır.

```
--GO
-------- * * ** ** * VERİ TABLOLARI OLUSTURUYORUZ * ** ** - -- - -- -
--CREATE TABLE RawCustomers_Source1 (
--    ID INT IDENTITY(1,1) PRIMARY KEY,
--    FullName NVARCHAR(100),
--    City NVARCHAR(50),
--    Phone NVARCHAR(50),
--    Email NVARCHAR(100)
--);
--GO

--CREATE TABLE RawCustomers_Source2 (
--    RecordID INT IDENTITY(1,1) PRIMARY KEY,
--    NameSurname NVARCHAR(100),
--    CityName NVARCHAR(50),
--    GSM NVARCHAR(50),
--    MailAddress NVARCHAR(100)
--);
--GO

--CREATE TABLE CleanCustomers (
--    CustomerID INT IDENTITY(1,1) PRIMARY KEY,
--    FullName NVARCHAR(100),
--    City NVARCHAR(50),
--    Phone NVARCHAR(20),
--    Email NVARCHAR(100),
--    SourceTable NVARCHAR(30)
--);
--GO
```

Şekil 2 : Oluşturulan Tabloların sütunları

4.Database oluşturma

Bu projede ETL sürecinin uygulanabilmesi için yeterli büyüklükte ve gerçekçi bir veri seti yapay zekadan yararlanılarak oluşturulmuştur . Bu amaçla RawCustomers_Source1 ve RawCustomers_Source2 tablolarına WHILE döngüsü kullanılarak yaklaşık 100'er adet kayıt eklenmiştir.

Veri üretim sürecinde rastgelelik ve veri çeşitliliği sağlamak amacıyla belirli koşullar (mod işlemleri) kullanılmıştır. Bu sayede her kayıt aynı yapıda olmamış, farklı veri problemleri bilinçli olarak veri setine dahil edilmiştir.

Oluşturulan veri setinde aşağıdaki veri kalitesi problemleri özellikle yer almaktadır:

- **NULL değerler:** Belirli aralıklarla bazı alanlar boş bırakılmıştır
- **Boş string değerler:** Görünürde dolu ancak aslında geçersiz veriler oluşturulmuştur

- **Hatalı formatlar:**
    - Telefon alanında abc123, eksik veya yanlış uzunlukta değerler
    - E-posta alanında @ içermeyen veya hatalı formatlar
- **Büyük/küçük harf tutarsızlıkları:** Veri standardizasyonu ihtiyacını göstermek amacıyla farklı yazım biçimleri kullanılmıştır
- **Başında/sonunda boşluk bulunan veriler:** LTRIM / RTRIM işlemlerini göstermek için
- **Tekrarlı kayıtlar (duplicate):** Veri temizleme aşamasında ayıklanması için

Veri üretimi sırasında bazı kayıtlar kasıtlı olarak tekrar eklenmiş ve veri seti genişletilmiştir. Bu sayede toplam kayıt sayısı:

- **Source1:** 104 kayıt , **Source2:** 105 kayıt

olacak şekilde oluşmuştur.

Bu yapı sayesinde gerçek dünyadaki veri problemleri simüle edilmiş ve ETL sürecinin tüm aşamalarının uygulanabileceği uygun bir test ortamı hazırlanmıştır.

```sql
--DECLARE @i INT = 1;

--WHILE @i <= 100
--BEGIN
--    INSERT INTO RawCustomers_Source1 (FullName, City, Phone, Email)
--    VALUES
--    (
--        CASE
--            WHEN @i % 15 = 0 THEN NULL
--            WHEN @i % 10 = 0 THEN ''
--            WHEN @i % 7 = 0 THEN '  musteri ' + CAST(@i AS NVARCHAR(10)) + '  '
--            WHEN @i % 6 = 0 THEN UPPER('musteri ' + CAST(@i AS NVARCHAR(10)))
--            ELSE 'Musteri ' + CAST(@i AS NVARCHAR(10))
--        END,

--        CASE
--            WHEN @i % 5 = 0 THEN 'ankara'
--            WHEN @i % 5 = 1 THEN 'ISTANBUL'
--            WHEN @i % 5 = 2 THEN ' izmir '
--            WHEN @i % 5 = 3 THEN 'Bursa'
--            ELSE 'antalya'
--        END,

--        CASE
--            WHEN @i % 12 = 0 THEN NULL
--            WHEN @i % 11 = 0 THEN 'abc123'
--            WHEN @i % 9 = 0 THEN '5' + RIGHT('000000000' + CAST(@i AS VARCHAR(9)), 9)
--            ELSE '05' + RIGHT('000000000' + CAST(@i AS VARCHAR(9)), 9)
--        END,

--        CASE
--            WHEN @i % 14 = 0 THEN NULL
--            WHEN @i % 8 = 0 THEN 'musteri' + CAST(@i AS VARCHAR(10)) + 'mail.com'
--            WHEN @i % 6 = 0 THEN 'MUSTERI' + CAST(@i AS VARCHAR(10)) + '@MAIL.COM'
--            ELSE 'musteri' + CAST(@i AS VARCHAR(10)) + '@mail.com'
--        END
--    );

--    IF @i % 20 = 0
--    BEGIN
--        INSERT INTO RawCustomers_Source1 (FullName, City, Phone, Email)
--        VALUES
--        (
--            'Musteri ' + CAST(@i AS NVARCHAR(10)),
--            'ankara',
--            '05' + RIGHT('000000000' + CAST(@i AS VARCHAR(9)), 9),
--            'musteri' + CAST(@i AS VARCHAR(10)) + '@mail.com'
--        );
--    END

--    SET @i = @i + 1;
--END;
--GO
```

Şekil 3 : AI yardımı ile tabloların hatalı ve NULL içeren şekilde doldurulması

5. Veri Temizleme ve ETL Süreci

Veri Analizi kısmı (EXTRACT) : İlk olarak RawCustomers_Source1 ve RawCustomers_Source2 tablolarındaki veriler analiz edilmiştir. Bu analiz kapsamında : Toplam kayıt sayıları belirlenmiş , Eksik (NULL veya boş) alanlar tespit edilmiş , Hatalı e-posta formatına sahip kayıtlar belirlenmiş , Tekrar eden (duplicate) veriler analiz edilmiştir.

Veri Temizleme Kısmı (TRANSFORM) : Bu aşamada ham veriler üzerinde çeşitli temizleme işlemleri uygulanmıştır:

Boş ve NULL değerler filtrelenmiştir . Geçersiz e-posta adresleri elenmiştir (LIKE '%@%.%' kontrolü ile) Tekrarlı kayıtlar kaldırılmıştır. (SELECT DISTINCT) Başında ve sonunda boşluk bulunan veriler temizlenmiştir (LTRIM, RTRIM) İsim ve şehir alanları standartlaştırılmıştır (tamamı büyük harfe çevrilmiştir) E-posta adresleri küçük harfe dönüştürülmüştür.

Veri Yükleme Kısmı(LOAD) : Temizlenmiş ve dönüştürülmüş veriler CleanCustomers tablosuna aktarılmıştır.

Bu işlem sırasında: Her kaynağın verisi ayrı ayrı işlenmiş ,Kaynak bilgisi korunarak (Source1, Source2) hedef tabloya eklenmiştir. Sadece geçerli ve temiz verilerin aktarılması sağlanmıştır.

```sql
------ ** * * ETL BASLANGIC **** - -- -- -  -- - -
--USE VizeProject2DB;
--GO

---- Source1 toplam kayıt
--SELECT COUNT(*) AS Source1_Total FROM RawCustomers_Source1;

---- Source1 eksik isim
--SELECT COUNT(*) AS Source1_MissingName
--FROM RawCustomers_Source1
--WHERE FullName IS NULL OR LTRIM(RTRIM(FullName)) = '';

---- Source1 eksik telefon
--SELECT COUNT(*) AS Source1_MissingPhone
--FROM RawCustomers_Source1
--WHERE Phone IS NULL OR LTRIM(RTRIM(Phone)) = '';

---- Source1 hatalı email
--SELECT COUNT(*) AS Source1_InvalidEmail
--FROM RawCustomers_Source1
--WHERE Email IS NULL OR Email NOT LIKE '%@%.%';

---- Source1 tekrar kayıt kontrolü
--SELECT FullName, City, Phone, Email, COUNT(*) AS RepeatCount
--FROM RawCustomers_Source1
--GROUP BY FullName, City, Phone, Email
--HAVING COUNT(*) > 1;
```

Şekil 4 : ETL sürecinin başlangıcında ham veriler üzerinde yapılan analiz sorguları

83 % 38 0 Sat: 208, Krkt: 3 SEKMELER CRLF UTF-8

Sonuçlar | İletiler

	Source1_Total
1	105

	Source1_MissingName
1	13

	Source1_MissingPhone
1	8

	Source1_InvalidEmail
1	18

FullName	City	Phone	Email	RepeatCount

	Source2_Total
1	104

	Source2_MissingName
1	17

	Source2_MissingPhone
1	7

	Source2_InvalidEmail
1	21

NameSurname	CityName	GSM	MailAddress	RepeatCount

Şekil 5 : Ham veri kaynaklarında (Source1 ve Source2) yapılan veri kalite analizi sonuçları

6. Veri Kalitesi Raporu

Bu aşamada ham veri kaynakları ile temizlenmiş veri karşılaştırılarak veri kalitesi incelendi.

Veri analiz sonuçlarına göre:

- **Source1 toplam kayıt sayısı:** 104 **Source2 toplam kayıt sayısı:** 105 , **Toplam ham veri:** 209 kayıt

ETL süreci sonucunda:

- **CleanCustomers tablosuna aktarılan veri:** 148 kayıt

Bu sonuçlara göre yaklaşık **61 kayıt** hatalı, eksik veya geçersiz veri içerdiği için sistemden elenmiştir.

Şekil 6 : ETL süreci öncesi ve sonrası veri miktarlarının karşılaştırılması ve hatalı verilerin elenmesinin gösterimi

7. ETL Sürecinin Önemi ve Gerçek Hayattaki Kullanımı

ETL (Extract, Transform, Load) süreçleri, günümüzde veri odaklı sistemlerin temel yapı taşlarından biri haline gelmiştir. Farklı kaynaklardan gelen veriler çoğu zaman eksik, hatalı veya tutarsız olabildiği için bu verilerin doğrudan kullanılması doğru sonuçlar üretmemektedir. Bu nedenle ETL süreçleri sayesinde veriler önce analiz edilmekte, ardından temizlenip standart bir formata dönüştürülerek güvenilir hale getirilmektedir.

Gerçek hayatta ETL süreçleri özellikle büyük veri ile çalışan sistemlerde yaygın olarak kullanılmaktadır. Bankacılık sektöründe müşteri işlemleri ve risk analizleri, e-ticaret sistemlerinde kullanıcı davranışlarının incelenmesi, sağlık sektöründe hasta verilerinin düzenlenmesi ve raporlanması gibi birçok alanda ETL süreçleri kritik rol oynamaktadır. Bu sistemlerde farklı veri kaynaklarından gelen bilgilerin tek bir merkezde toplanması ve analiz edilebilir hale getirilmesi ETL sayesinde mümkün olmaktadır.

Ayrıca iş zekâsı (Business Intelligence) ve veri analitiği uygulamalarında doğru ve güvenilir sonuçlar elde edebilmek için veri kalitesinin yüksek olması gerekmektedir. ETL süreçleri bu noktada veri kalitesini artırarak karar destek sistemlerinin daha doğru ve etkin çalışmasını sağlamaktadır.

Bu proje kapsamında gerçekleştirilen uygulama da gerçek dünya senaryolarını simüle etmekte olup, ham verinin doğrudan kullanılmasının ne kadar riskli olduğunu ve ETL süreçlerinin veri güvenilirliği açısından ne kadar önemli olduğunu açıkça ortaya koymaktadır.

8. Sonuçlar

Bu projede ETL süreci kapsamında farklı veri kaynaklarından elde edilen ham veriler analiz edilmiş, veri kalitesi problemleri tespit edilmiş ve bu veriler çeşitli temizleme ve dönüştürme işlemlerinden geçirilerek standart bir yapıya kavuşturulmuştur. Proje başlangıcında RawCustomers_Source1 ve RawCustomers_Source2 tablolarında toplam **209 adet ham veri** bulunduğu görülmüştür.

Yapılan analizler sonucunda ham veri içerisinde eksik alanlar, hatalı e-posta formatları, geçersiz telefon numaraları ve tekrar eden kayıtlar tespit edilmiştir. Bu veri problemlerinin giderilmesi amacıyla uygulanan ETL süreci sonrasında yalnızca geçerli ve standartlara uygun veriler CleanCustomers tablosuna aktarılmıştır. Bu süreç sonunda temiz tabloya aktarılan veri sayısı **148 kayıt** olarak belirlenmiştir.

Bu sonuçlar değerlendirildiğinde yaklaşık **61 adet kaydın** hatalı, eksik veya geçersiz veri içerdiği için sistemden elendiği görülmektedir. Bu da toplam veri setinin yaklaşık **%29'unun** veri kalitesi problemleri nedeniyle temizleme sürecinde çıkarıldığını göstermektedir.

Veri temizleme sürecinde yalnızca hatalı kayıtların elenmesi değil, aynı zamanda veri standardizasyonu da sağlanmıştır. İsim ve şehir alanları standart formata getirilmiş, e-posta adresleri normalize edilmiş ve telefon numaraları belirli kurallara göre düzenlenmiştir. Bu sayede veri bütünlüğü korunmuş ve analiz yapılabilir güvenilir bir veri seti elde edilmiştir.

Sonuç olarak, uygulanan ETL süreci sayesinde veri kalitesi önemli ölçüde artırılmış, hatalı ve tutarsız veriler sistemden ayrıştırılmış ve elde edilen temiz veri seti analiz süreçleri için uygun hale getirilmiştir. Bu çalışma, veri temizleme ve veri dönüştürme işlemlerinin veri analizi ve karar destek sistemleri açısından ne kadar kritik olduğunu nicel verilerle ortaya koymaktadır.